

MANUAL DO PRODUTO

Animus

Documentação técnica do sistema

ANIMU



Guia técnico para desenvolvedores e equipes de engenharia
sobre a arquitetura, pipeline de IA, modelo ML
e infraestrutura do Animus.

VERSÃO

1.0

DATA

20/05/2026

STATUS

Publicado

Público-alvo: Desenvolvedores, engenheiros e equipes técnicas

1. Visão Geral do Sistema

O Animus é um aplicativo mobile que auxilia juízes e advogados na análise de documentos processuais e na identificação de precedentes jurídicos aplicáveis. O sistema utiliza um pipeline de RAG (Retrieval-Augmented Generation) para processar petições iniciais, realizar busca semântica na base nacional de precedentes (Pangea) e gerar relatórios e minutas com apoio de modelos de linguagem.

O app oferece dois fluxos de análise completamente independentes:

- **Análise Inicial** — upload de petição inicial (PDF/DOCX), extração de resumo, busca e ranqueamento de precedentes, síntese explicativa e escolha do precedente. Disponível para Juízes e Advogados.
- **Análise para 2ª Instância** — upload de autos completos (PDF), extração automática da petição inicial, busca de precedentes e geração de minuta de sentença estruturada. Exclusivo para Juízes.

O projeto é de código aberto, hospedado no GitHub, e a equipe Ctrl Alt Del é responsável pela disponibilização e operação do sistema.

2. Arquitetura do Sistema

2.1 Visão geral das camadas

Camada	Responsabilidade	Tecnologia principal
Mobile (Frontend)	Interface do usuário, navegação, upload de documentos, exibição de análises	Flutter (Android e iOS)
Backend (API)	Regras de negócio, autenticação, orquestração de fluxos, geração de PDFs	Python (FastAPI)
IA / ML	Pipeline RAG, análise de petições, busca semântica, geração de minutas, classificação de aplicabilidade	Python, XGBoost, LLM (GPT-4o via Agno), RAG Híbrido
Infraestrutura	Contêinerização, CI/CD, cloud hosting, armazenamento de arquivos	Docker, GCP, GitHub Actions

2.2 Plataforma e hospedagem

O sistema é hospedado na Google Cloud Platform (GCP), seguindo uma arquitetura Cloud Native. O backend roda em containers Docker gerenciados na nuvem.

2.3 Banco de dados

O sistema utiliza PostgreSQL como banco relacional, acessado via ORM (SQLAlchemy). O modelo de dados central inclui as seguintes entidades principais:

Entidade	Descrição
Account	Dados da conta do usuário (nome, e-mail, senha hash, status ativo/inativo para soft delete, contas sociais vinculadas)
Analysis	Registro de cada análise criada, associada à conta, com tipo (initial/second_instance) e status
Petition	Documento processual enviado (referência ao arquivo armazenado no GCS)
PetitionSummary	Resumo estruturado gerado pela IA (case_summary, legal_issue, central_question, relevant_laws, key_facts, search_terms)
AnalysisPrecedent	Precedente retornado pela busca, com scores, síntese e nível de classificação
PetitionDraft	Rascunho de minuta de petição gerado para o Advogado
SentenceDraft	Rascunho de minuta de sentença gerado para o Juiz de 2ª instância
Folder	Pastas criadas pelo usuário para organizar análises

2.4 Armazenamento de arquivos

Arquivos enviados pelos usuários (petições em PDF/DOCX e autos em PDF) são armazenados no Google Cloud Storage (GCS). Os PDFs gerados (relatórios e minutas) são entregues via share sheet nativo do dispositivo (Android e iOS). Os datasets de treino do modelo ML são exportados em Parquet e armazenados no GCS.

3. Autenticação e Gerenciamento de Sessão

A autenticação do app suporta dois métodos:

- **E-mail e senha** — cadastro e login padrão com hash seguro (bcrypt)
- **OAuth com Google** — login social via conta Google (OAuth 2.0)

A redefinição de senha utiliza um código OTP de 6 dígitos enviado por e-mail. O fluxo inclui verificação do OTP, emissão de um contexto temporário opaco e redefinição da senha sem exposição de identificadores internos ao cliente.

A sessão é baseada em JWT com access token e refresh token. O app mobile implementa um interceptor Dio que renova automaticamente a sessão via POST /auth/refresh quando o access token expira, eliminando expiração silenciosa durante uso ativo.

A exclusão de conta segue o padrão de soft delete: o campo `is_active` é definido como `false` e os dados são preservados. O sistema possui um único tipo de perfil de usuário — não há perfil ADMIN.

4. Pipeline de IA — RAG Híbrido

4.1 Fonte de dados de precedentes

A base de precedentes utilizada é o Pangea (pangeabnp.pdpj.jus.br), a base nacional de precedentes do Poder Judiciário brasileiro, consumida via API.

4.2 Fluxo da Análise Inicial (RAG)

1. **Ingestão do documento** — O arquivo PDF ou DOCX é recebido e armazenado no GCS. O texto é extraído.
2. **Geração do resumo** — Um LLM (GPT-4o) processa o texto e gera o `PetitionSummary` com campos estruturados: `case_summary`, `legal_issue`, `central_question`, `relevant_laws`, `key_facts` e `search_terms`.
3. **Busca semântica (RAG Híbrido)** — Busca sobre os campos questão, tese e ementa dos precedentes do Pangea, combinando busca densa (embeddings), esparsa (BM25) e Reciprocal Rank Fusion (RRF).
4. **Ranqueamento de aplicabilidade** — O modelo ML (XGBoost) classifica cada par petição-precedente com um `applicability_percentage` calculado a partir de 8 features numéricas.
5. **Síntese explicativa** — Para cada precedente, um LLM gera uma síntese textual. Para advogados (RF 07), é gerada também uma justificativa de aderência.
6. **Persistência** — Todos os dados são persistidos no banco associados à conta do usuário.

4.3 Fluxo da Análise para 2ª Instância

1. **Upload dos autos** — O PDF completo é recebido e armazenado no GCS.

2. **Extração da petição** — O sistema identifica e extrai automaticamente a petição inicial dos autos. O Juiz confirma ou corrige antes de prosseguir.
3. **Deteção do contexto** — O sistema identifica automaticamente o contexto de 2ª instância a partir do conteúdo.
4. **Busca de precedentes** — Mesmo pipeline RAG da Análise Inicial.
5. **Geração da minuta** — Um LLM gera a minuta com quatro seções: relatório, fundamentação, análise de aderência/distinção e dispositivo sugerido.
6. **Aviso de ausência** — Quando nenhum precedente for classificado como "Aplicável" ($\geq 85\%$), o sistema ativa um aviso visual na tela e no PDF exportado.

Tanto a minuta de petição (advogado) quanto a minuta de sentença (juiz) suportam **regeração orientada por comentários**: o usuário pode solicitar uma nova versão incluindo instruções textuais, sem reenviar documentos nem resselecionar precedentes. A nova versão substitui a anterior.

4.4 Timeout e resiliência

Todas as operações de processamento de IA possuem timeout de 60 segundos. Se o limite for atingido, o sistema cancela, notifica o usuário e oferece opção de retentar.

5. Modelo de Aplicabilidade (ML)

5.1 Visão geral

O Applicability Score é independente do similarity_percentage do RAG. Mede a probabilidade de um precedente ser juridicamente aplicável, levando em conta hierarquia do tribunal, força vinculante e atualidade.

5.2 Modelo e saída

O modelo é XGBClassifier com objective='multi:softprob' e num_class=3. A saída são três probabilidades que somam 1. O applicability_percentage é calculado como:

```
applicability_percentage = proba[:,0]*0 + proba[:,1]*50 + proba[:,2]*95
```

A faixa vai de 0% a 95% — o cap em 95% preserva a necessidade de avaliação humana final.

5.3 Features do modelo

Feature	Tipo	Descrição
thesis_similarity_score	float [0,1]	Maior score RRF do campo tese
enunciation_similarity_score	float [0,1]	Maior score RRF do campo ementa
total_search_hits	int	Quantidade de chunks que encontraram este precedente
similarity_rank	int	Posição no ranking de similaridade semântica
precedent_kind_authority	int [1–5]	Força vinculante: SV=5, SUM/RG=4, IRDR/TR=3, OJ=2, outros=1
court_hierarchy	int [1–5]	Hierarquia: STF=5, STJ/TST=4, TRF/TRT=3, TJ=2, outros=1
precedent_status	int	Vigente=1, Transitado em julgado=0
last_updated_in_pangea_at	timestamp → days	Atualidade do precedente na base Pangea

5.4 Categorias de aplicabilidade (exibição)

Os thresholds de exibição aplicados sobre o applicability_percentage para classificar cada precedente na interface e no PDF:

Faixa	Categoria	Cor
≥ 85%	Aplicável	Verde (success)
≥ 70% e < 85%	Possivelmente aplicável	Amarelo (warning)

Faixa	Categoria	Cor
< 70%	Não aplicável	Vermelho (danger)

5.5 Dataset e estratégia de cold start

O dataset inicial é gerado pelo job `SeedAnalysesPrecedentsDatasetJob`, que processa 20 petições fornecidas pela Xertica. Para cada petição, são buscados K=20 precedentes e classificados por um agente GPT-4o (via Agno) com 3 steps. O resultado esperado é ~400 pares rotulados. Rótulos de usuários reais (`is_from_human=True`) têm prioridade sobre rótulos sintéticos. O split usa `GroupShuffleSplit` agrupado por `analysis_id` para evitar data leakage.

6. Infraestrutura e DevOps

6.1 Containerização

O backend é containerizado com Docker e implantado na GCP.

6.2 Pipelines de CI/CD

- **CI** — Testes e validações automatizados a cada push/PR
- **CD** — Deploy automatizado na GCP com pipelines separadas para mobile, server e IaC

6.3 Infraestrutura como Código (IaC)

A infraestrutura da GCP é gerenciada como código (IaC) via Terraform, permitindo provisionamento reproduzível e versionado.

7. Segurança e Conformidade

7.1 LGPD

- Dados de conta preservados em soft delete — sem exclusão física
- Não são armazenados dados sigilosos específicos do processo judicial
- Não há dados de perfil jurídico (OAB, cargo)
- Não há exposição de dados de um usuário para outro

7.2 Autenticação e autorização

Autenticação via e-mail/senha com hash seguro (bcrypt) e OAuth 2.0 para Google. Redefinição de senha via OTP de 6 dígitos. Sessão JWT com refresh token e renovação automática. Único nível de autorização (usuário comum).

8. Filtros e Regras de Negócio da Busca

8.1 Filtros disponíveis

- **Tribunal** — se selecionado, restringe a busca ao tribunal informado
- **Tipo/espécie** — filtro adicional opcional pelo tipo do precedente

Sem filtros, a busca é feita na base completa do Pangea.

8.2 Quantidade de resultados

A busca retorna entre 5 e 10 precedentes (padrão 10), organizados por nível de aplicabilidade: Aplicável → Possivelmente aplicável → Não aplicável. O usuário também pode adicionar um precedente manualmente à análise por identificador.

8.3 Filtragem por status do precedente

Status	Comportamento
Vigente, Transitado em julgado	Exibido normalmente
Afetado, Controvérsia vinculada	Exibido com aviso visual
Cancelado, Não admitido, Controvérsia cancelada	Nunca retornado

9. Geração de PDFs

A geração de PDFs é realizada pelo app mobile a partir dos dados da análise concluída. Os PDFs são entregues via share sheet nativo do dispositivo (Android e iOS). O nome do arquivo segue o formato:

[Nome da análise] – Relatório.pdf

A exportação está disponível apenas para análises com status Concluído.

10. Limites e Restrições do Sistema

Restrição	Valor
Tamanho máximo de arquivo	20 MB
Formatos aceitos (Análise Inicial)	PDF, DOCX
Formatos aceitos (Análise 2ª Instância)	PDF apenas

Restrição	Valor
Timeout de processamento IA	60 segundos
Precedentes retornados por busca	5–10 (padrão 10)
Cap do applicability_percentage	95%
Tamanho máximo do nome de pasta	50 caracteres
Tamanho máximo do nome de análise	100 caracteres
Leitura de imagens nos documentos	Não suportado
Plataforma	Mobile (Android e iOS)
Tema visual	Dark e light mode

11. Fora do Escopo

- Versão web do aplicativo
- Leitura de imagens dentro das petições ou autos
- Chat conversacional com a IA
- Perfil ADMIN ou dashboard de gestão de usuários
- Edição direta do conteúdo de minutas no app
- Armazenamento de dados sigilosos do processo judicial
- Dados de perfil jurídico (OAB, cargo)

12. Referências

- Requisitos do Produto (Confluence — space ANM)
- Arquitetura do Sistema — Animus
- Applicability Score — Decisões de Design
- Glossário Jurídico — Conceitos do Domínio do Animus
- Design no Figma
- Base Pangea — Precedentes do Poder Judiciário